고객을 세그먼테이션하자 [프로젝트]

11-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
select * from white-might-456101-t9.modulabs_project.data limit 10;
```

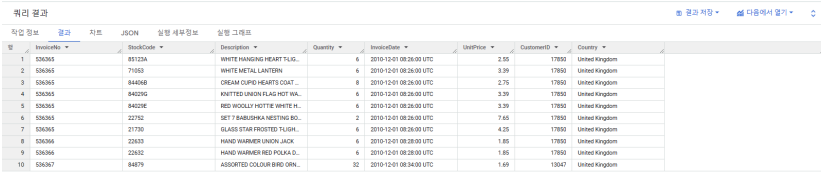

쿼리 결과

결과 저장 다음에서 열기

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	2.55	17850	United Kingdom
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
3	536365	84406B	CREAM CUPID HEARTS COAT ...	8	2010-12-01 08:26:00 UTC	2.75	17850	United Kingdom
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	7.65	17850	United Kingdom
7	536365	21730	GLASS STAR FROSTED T-LIGH...	6	2010-12-01 08:26:00 UTC	4.25	17850	United Kingdom
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
9	536366	22632	HAND WARMER RED POLKA D...	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-01 08:34:00 UTC	1.69	13047	United Kingdom

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
select count(*) as total_count from white-might-456101-t9.modulabs_project.data;
```

쿼리 결과

결과 저장 다음에서 열기

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	total_count
1	541909

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
SELECT
  COUNT(InvoiceNo) AS InvoiceNo_count,
  COUNT(StockCode) AS StockCode_count,
  COUNT(Description) AS Description_count,
  COUNT(Quantity) AS Quantity_count,
  COUNT(InvoiceDate) AS InvoiceDate_count,
  COUNT(UnitPrice) AS UnitPrice_count,
  COUNT(CustomerID) AS CustomerID_count,
  COUNT(Country) AS Country_count
FROM
  `white-might-456101-t9.modulabs_project.data`;
```

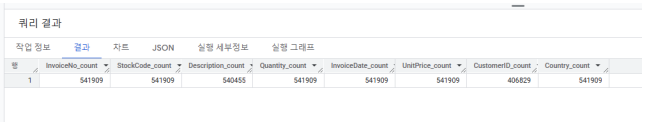

쿼리 결과

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	InvoiceNo_count	StockCode_count	Description_count	Quantity_count	InvoiceDate_count	UnitPrice_count	CustomerID_count	Country_count
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
SELECT column_name, ROUND((total - column_value) / total * 100, 2)
FROM
(
   SELECT 'InvoiceNo' AS column_name, COUNT(InvoiceNo) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.mo
   SELECT 'StockCode' AS column_name, COUNT(StockCode) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.m
   SELECT 'Description' AS column_name, COUNT(Description) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.
   SELECT 'Quantity' AS column_name, COUNT(Quantity) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.modul
   SELECT 'InvoiceDate' AS column_name, COUNT(InvoiceDate) AS column_value, COUNT(*) AS total FROM white-might-456101-t9
   SELECT 'UnitPrice' AS column_name, COUNT(UnitPrice) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.mod
   SELECT 'CustomerID' AS column_name, COUNT(CustomerID) AS column_value, COUNT(*) AS total FROM white-might-456101-t9
   SELECT 'Country' AS column_name, COUNT(Country) AS column_value, COUNT(*) AS total FROM white-might-456101-t9.modula
) AS column_data;
```

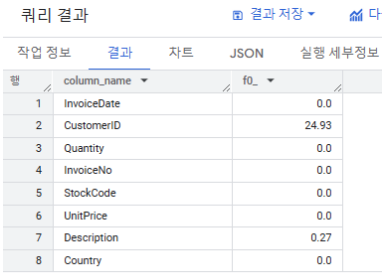

행	column_name	f0_
1	InvoiceDate	0.0
2	CustomerID	24.93
3	Quantity	0.0
4	InvoiceNo	0.0
5	StockCode	0.0
6	UnitPrice	0.0
7	Description	0.27
8	Country	0.0

결측치 처리 전략

- `StockCode = '85123A'` **의** `Description` **을 추출하는 쿼리문을 작성하기**

```
select distinct Description from white-might-456101-t9.modulabs_project.data where StockCode  = '85123A';
```

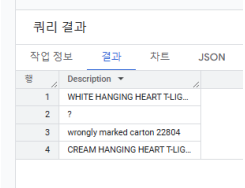

행	Description
1	WHITE HANGING HEART T-LIG...
2	?
3	wrongly marked carton 22804
4	CREAM HANGING HEART T-LIG...

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
delete FROM `white-might-456101-t9.modulabs_project.data`
WHERE CustomerID IS NULL OR Description IS NULL;
```

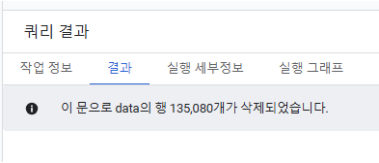

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
SELECT COUNT(*) AS double_count
FROM (
  SELECT *
  FROM `white-might-456101-t9.modulabs_project.data`
  GROUP BY InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
  HAVING COUNT(*) > 1
);
```

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
CREATE OR REPLACE TABLE `white-might-456101-t9.modulabs_project.data` AS
SELECT DISTINCT *
FROM `white-might-456101-t9.modulabs_project.data`;
```

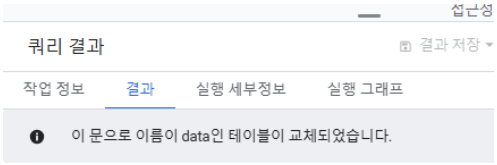

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- **고유(unique)한 InvoiceNo 의 개수를 출력하기**

```
select count(distinct InvoiceNo)
from white-might-456101-t9.modulabs_project.data;
```

쿼리 결과

작업 정보 | 결과 | 차트

행	f0_
1	22190

- **고유한 `InvoiceNo` 를 앞에서부터 100개를 출력하기**

```
select distinct InvoiceNo
from white-might-456101-t9.modulabs_project.data
limit 100;
```

쿼리 결과 | 결과 저장 | 다음에서 열기

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	InvoiceNo
1	541431
2	C541433
3	537626
4	542237
5	549222
6	556201
7	562032
8	573511
9	581180
10	539318
11	541998
12	548955
13	568172
14	577609

- **`InvoiceNo` 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
select *
from white-might-456101-t9.modulabs_project.data
where InvoiceNo LIKE 'C%'
limit 100;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
30	C565050	23243	SET OF TEA COFFEE SUGAR TI...	-2	2011-08-31 17:10:00 UTC	4.95	12381	Norway
31	C565050	85159B	WHITE TEA,COFFEE,SUGAR JA...	-1	2011-08-31 17:10:00 UTC	1.95	12381	Norway
32	C565050	21791	VINTAGE HEADS AND TAILS C...	-12	2011-08-31 17:10:00 UTC	1.25	12381	Norway
33	C565050	23198	PANTRY MAGNETIC SHOPPIN...	-10	2011-08-31 17:10:00 UTC	1.45	12381	Norway
34	C541586	21218	RED SPOTTY BISCUIT TIN	-3	2011-01-19 14:36:00 UTC	3.75	12383	Belgium
35	C567540	23295	SET OF 12 MINI LOAF BAKING ...	-2	2011-09-21 10:00:00 UTC	0.83	12384	Switzerland
36	C567540	23173	REGENCY TEAPOT ROSES	-1	2011-09-21 10:00:00 UTC	9.95	12384	Switzerland
37	C567540	84279P	CHERRY BLOSSOM DECORATI...	-2	2011-09-21 10:00:00 UTC	3.75	12384	Switzerland
38	C540152	22666	RECIPE BOX PANTRY YELLOW ...	-1	2011-01-05 11:21:00 UTC	2.95	12395	Belgium
39	C544419	85232A	SET/3 POLKADOT STACKING T...	-3	2011-02-18 15:16:00 UTC	4.95	12395	Belgium
40	C578432	21559	STRAWBERRY LUNCH BOX WI...	-1	2011-11-24 12:20:00 UTC	2.55	12395	Belgium
41	C572187	POST	POSTAGE	-1	2011-10-21 11:00:00 UTC	18.0	12403	Denmark
42	C562728	22849	BREAD BIN DINER STYLE MINT	-1	2011-08-09 09:41:00 UTC	14.95	12406	Denmark
43	C562728	22846	BREAD BIN DINER STYLE RED	-4	2011-08-09 09:41:00 UTC	14.95	12406	Denmark
44	C562728	22848	BREAD BIN DINER STYLE PINK	-4	2011-08-09 09:41:00 UTC	14.95	12406	Denmark

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
SELECT ROUND(SUM(CASE WHEN InvoiceNo like 'C%' THEN 1 ELSE 0 END)/ count(InvoiceNo) * 100, 1) as Canceled_Percent
from white-might-456101-t9.modulabs_project.data
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	Canceled_Percent
1	2.2

StockCode 살펴보기

- **고유한 StockCode 의 개수를 출력하기**

```
select count(distinct StockCode)
from white-might-456101-t9.modulabs_project.data;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	f0_
1	3684

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
from white-might-456101-t9.modulabs_project.data
group by StockCode
ORDER BY sell_cnt DESC
limit 10;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	StockCode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110
10	23203	1108

- **StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  from white-might-456101-t9.modulabs_project.data
)
WHERE number_count between 0 and 1;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	StockCode	number_count
1	POST	0
2	M	0
3	C2	1
4	D	0
5	BANK CHARGES	0
6	PADS	0
7	DOT	0
8	CRUK	0

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
-- 숫자가 0~1개인 값
WITH no_char_codes AS (
  SELECT DISTINCT StockCode
  FROM (
    SELECT StockCode,
      LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM `white-might-456101-t9.modulabs_project.data`
  )
  WHERE number_count BETWEEN 0 AND 1
),

-- no_char_codes에서 distinct StockCode에 출력된 결과만을 포함하는 전체 데이터수
filter_no_char_codes AS (
select count(*) as row_count
from `white-might-456101-t9.modulabs_project.data`
where StockCode in (select StockCode from no_char_codes)
),

-- data 테이블의 전체 덴이터 행 수
total AS (
  select count(*) as total_count from `white-might-456101-t9.modulabs_project.data`
)

select ROUND( row_count / total.total_count * 100, 2) as no_char_stockcode_percent
from filter_no_char_codes, total;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	no_char_stockcode_p
1	0.48

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
delete from `white-might-456101-t9.modulabs_project.data`
where StockCode in (
    SELECT DISTINCT StockCode
  FROM (
    SELECT StockCode,
      LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM `white-might-456101-t9.modulabs_project.data`
```

```
  )
  WHERE number_count BETWEEN 0 AND 1
);
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 data의 행 1,915개가 삭제되었습니다.

Description 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT DISTINCT Description,COUNT(*) AS description_cnt
FROM `white-might-456101-t9.modulabs_project.data`
WHERE REGEXP_CONTAINS(Description, r'[a-z]')
group by Description
order by description_cnt DESC
limit 30;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	Description	description_cnt
1	BAG 125g SWIRLY MARBLES	252
2	3 TRADITIONAl BISCUIT CUTT...	207
3	BAG 250g SWIRLY MARBLES	201
4	POLYESTER FILLER PAD 40x40...	185
5	POLYESTER FILLER PAD 45x45...	135
6	BAG 500g SWIRLY MARBLES	115
7	Next Day Carriage	80
8	FRENCH BLUE METAL DOOR SI...	75
9	POLYESTER FILLER PAD 45x30...	37
10	POLYESTER FILLER PAD 30CM...	26
11	ESSENTIAL BALM 3.5g TIN IN ...	18
12	NUMBER TILE COTTAGE GARD...	12
13	FOLK ART GREETING CARD,pa...	10
14	THE KING GIFT BAG 25x24x12...	7
15	NUMBER TILE VINTAGE FONT ...	7
16	POLYESTER FILLER PAD 65CM...	5
17	High Resolution Image	3
18	FLOWERS HANDBAG blue and ...	3
19	POLYESTER FILLER PAD 60x40...	1

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
delete from `white-might-456101-t9.modulabs_project.data`
where Description = 'Next Day Carriage' or Description = 'High Resolution Image';
```

정답코드

```
DELETE
FROM project_name.modulabs_project.data
WHERE
Description LIKE '%Next Day Carriage%'
OR Description LIKE '%High Resolution Image%';
```

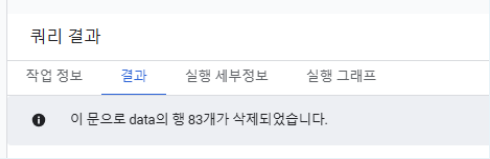

지정된 문자열이 아니고 “서비스 관련 정보를 포함하는” 이므로 %연산자 사용이 맞다고 봄.

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE white-might-456101-t9.modulabs_project.data AS
SELECT
  * EXCEPT (Description),
UPPER(Description) AS Description
FROM white-might-456101-t9.modulabs_project.data
```

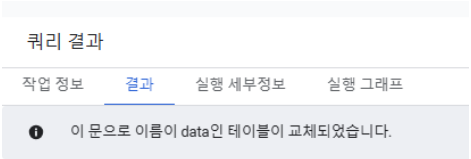

UnitPrice 살펴보기

- **UnitPrice 의 최솟값, 최댓값, 평균을 구하기**

```
select min(UnitPrice) as min_price, max(UnitPrice) as max_price, avg(UnitPrice) as avg_price
from `white-might-456101-t9.modulabs_project.data`
```

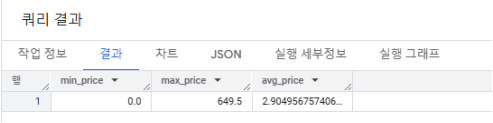

- **단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기**

```
SELECT count(Quantity) AS cnt_quantity, min(Quantity) AS min_quantity, max(Quantity) AS max_quantity,avg(Quantity) AS avg_quar
FROM `white-might-456101-t9.modulabs_project.data`
WHERE UnitPrice = 0
```

- **UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기**

```
CREATE OR REPLACE TABLE `white-might-456101-t9.modulabs_project.data` AS
SELECT *
FROM `white-might-456101-t9.modulabs_project.data`
WHERE UnitPrice != 0;
```

정답 코드

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT *
FROM project_name.modulabs_project.data
WHERE UnitPrice > 0;
```

가격이 음수가 될 순 없으니 `>0` 이 더 직관적인 표현이라고 봄.

11-7. RFM 스코어

Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
SELECT Date(InvoiceDate) AS InvoiceDay, *
FROM `white-might-456101-t9.modulabs_project.data`;
```

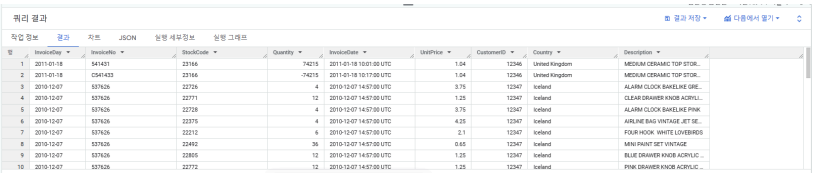

행	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	Description
1	2011-01-18	541431	23166	-74215	2011-01-18 10:01:00 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP STOR...
2	2011-01-18	C541433	23166	-74215	2011-01-18 10:17:00 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP STOR...
3	2010-12-07	537626	22726	4	2010-12-07 14:57:00 UTC	3.75	12347	Iceland	ALARM CLOCK BAKELIKE GRE...
4	2010-12-07	537626	22771	12	2010-12-07 14:57:00 UTC	1.25	12347	Iceland	CLEAR DRAWER KNOB ACRYLL...
5	2010-12-07	537626	22728	4	2010-12-07 14:57:00 UTC	3.75	12347	Iceland	ALARM CLOCK BAKELIKE PINK
6	2010-12-07	537626	22375	4	2010-12-07 14:57:00 UTC	4.25	12347	Iceland	AIRLINE BAG VINTAGE JET SE...
7	2010-12-07	537626	22212	6	2010-12-07 14:57:00 UTC	2.1	12347	Iceland	FOUR HOOK WHITE LOVEBIRDS
8	2010-12-07	537626	22492	36	2010-12-07 14:57:00 UTC	0.65	12347	Iceland	MINI PAINT SET VINTAGE
9	2010-12-07	537626	22805	12	2010-12-07 14:57:00 UTC	1.25	12347	Iceland	BLUE DRAWER KNOB ACRYLIC ...
10	2010-12-07	537626	22772	12	2010-12-07 14:57:00 UTC	1.25	12347	Iceland	PINK DRAWER KNOB ACRYLIC ...

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT MAX(DATE(InvoiceDate)) AS most_recent_date
FROM `white-might-456101-t9.modulabs_project.data`;
```

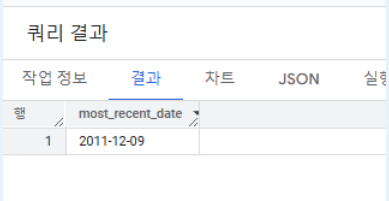

정답코드

```
SELECT
  MAX(DATE(InvoiceDate)) OVER () AS most_recent_date,
  DATE(InvoiceDate) AS InvoiceDay,
  *
FROM project_name.modulabs_project.data;
```

왜 over구문인지? → 꼭 필요한 구문은 아니나 모든 행에 추가해서 보여줄 경우 사용.

📌 차이를 한 줄로 말하면?

- `MAX()` → 전체 요약
- `MAX() OVER ()` → 전체 요약값을 모든 행에 추가해서 보여줌

OVER() 구문을 쓰지 않았다고 해서 오답 코드는 아니라고 봄.

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT
  CustomerID, MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM`white-might-456101-t9.modulabs_project.data`
group by CustomerID
```

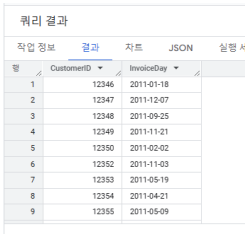

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
 CustomerID,
 EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
 SELECT
  CustomerID,
  MAX(DATE(InvoiceDate)) AS InvoiceDay
 FROM `white-might-456101-t9.modulabs_project.data`
 GROUP BY CustomerID
);
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그라

행	CustomerID	recency
1	12399	119
2	12448	44
3	12700	7
4	12718	71
5	13369	354
6	13436	1
7	13606	29
8	13823	18
9	14142	373
10	14196	106

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE `white-might-456101-t9.modulabs_project.user_r` AS
WITH rd AS (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM `white-might-456101-t9.modulabs_project.data`
  GROUP BY CustomerID
),
rd2 AS (
  SELECT
    MAX(DATE(InvoiceDate)) AS most_recent_date
  FROM `white-might-456101-t9.modulabs_project.data`
)
SELECT
  rd.CustomerID,
  rd.InvoiceDay,
  rd2.most_recent_date,
DATE_DIFF(rd2.most_recent_date, rd.InvoiceDay, DAY) AS recency
FROM rd, rd2;
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 이름이 user_r인 테이블이 교체되었습니다.

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  count(distinct invoiceNo) AS purchase_cnt
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	CustomerID	purchase_cnt
1	12457	1
2	12647	1
3	13985	1
4	15107	1
5	16818	1
6	12444	1
7	13014	1
8	14410	1
9	15804	1
10	15602	1

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
  CustomerID, SUM(Quantity) AS item_cnt
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID;
```

쿼리 결과 | 결과 저장 | 다음에서 열기

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	CustomerID	item_cnt
1	12346	0
2	12347	2458
3	12348	2332
4	12349	630
5	12350	196
6	12352	463
7	12353	20
8	12354	530
9	12355	240
10	12356	1573

페이지당 결과 수: 50 | 1 – 50 (전체 4362행)

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	CustomerID	item_cnt
16	12507	1
17	12431	1
18	14110	1
19	17560	1
20	13081	4
21	13239	1
22	12415	2
23	14646	4
24	13256	1

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE white-might-456101-t9.modulabs_project.user_rf AS
WITH purchase_cnt AS (
SELECT
  CustomerID,
  count(distinct invoiceNo) AS purchase_cnt
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID
),

-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
SELECT
  CustomerID, SUM(Quantity) AS item_cnt
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID
)
```

```
-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN `white-might-456101-t9.modulabs_project.user_r` AS ur
  ON pc.CustomerID = ur.CustomerID;
```

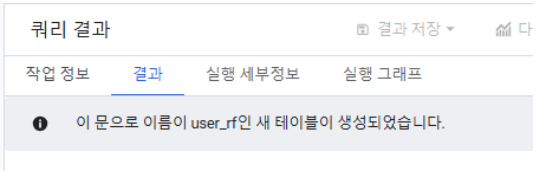

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT CustomerID,
ROUND(SUM(UnitPrice), 1) AS user_total
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID;
```

행	CustomerID	user_total
1	12346	2.1
2	12347	481.2
3	12348	18.7
4	12349	305.1
5	12350	25.3
6	12352	330.5
7	12353	24.3
8	12354	261.2
9	12355	54.7

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기**

```
CREATE OR REPLACE TABLE white-might-456101-t9.modulabs_project.user_rfm AS

SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
```

```
  rf.recency,
  ut.user_total,
  round(ut.user_total / rf.purchase_cnt,2) AS user_average
FROM white-might-456101-t9.modulabs_project.user_rf rf
LEFT JOIN (
SELECT CustomerID,
ROUND(SUM(UnitPrice), 1) AS user_total
FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 이름이 user_rfm인 테이블이 교체되었습니다.

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
select * FROM `white-might-456101-t9.modulabs_project.user_rfm`
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	77.1	77.1
2	13298	1	96	1	7.5	7.5
3	15520	1	314	1	31.0	31.0
4	13436	1	76	1	70.0	70.0
5	14569	1	79	1	47.0	47.0
6	15471	1	256	2	146.4	146.4
7	15195	1	1404	2	2.8	2.8
8	14204	1	72	2	99.2	99.2
9	15318	1	642	3	19.3	19.3

고유한 CustomerID 수

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	f0_
1	4362

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` **테이블과 결과를 합치기**
  3) `user_data` **라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE `white-might-456101-t9.modulabs_project.user_data` AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM `white-might-456101-t9.modulabs_project.data`
  GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM white-might-456101-t9.modulabs_project.user_rfm AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

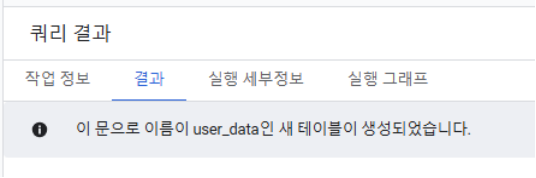

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를** `user_data` **에 통합**

```
CREATE OR REPLACE TABLE `white-might-456101-t9.modulabs_project.user_data` AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
    FROM
      `white-might-456101-t9.modulabs_project.data`
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM `white-might-456101-t9.modulabs_project.user_data` AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

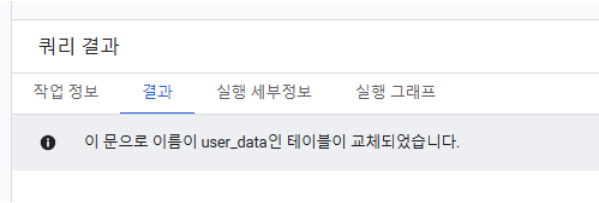

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE`white-might-456101-t9.modulabs_project.user_data` AS
WITH TransactionInfo AS (
  SELECT
    CustomerID,
count(case when InvoiceNo LIKE 'C%' then 1 end) AS cancel_frequency,
COUNT(InvoiceNo) AS total_transactions
  FROM `white-might-456101-t9.modulabs_project.data`
group by CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID), round( (t.cancel_frequency / t.total_transactions)*100, 2) AS cancel_rate
FROM `white-might-456101-t9.modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

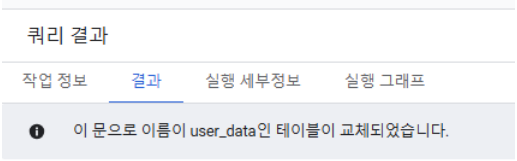

정답코드

```
CREATE OR REPLACE TABLE `project_name.modulabs_project.user_data` AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT InvoiceNo) AS total_transactions,
    COUNT(DISTINCT CASE WHEN InvoiceNo LIKE 'C%' THEN InvoiceNo END) AS cancel_frequency
  FROM `project_name.modulabs_project.data`
  GROUP BY CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID), ROUND(cancel_frequency/total_transactions, 2) AS cancel_rate
FROM `project_name.modulabs_project.user_data` AS u
```

```
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

`COUNT(DISTINCT CASE WHEN ~ THEN 1)`

C로 시작하는 invoiceNo가 1이 되어서 1인 행들만 카운트하면 취소된 거래 수를 셀 수 있다고 판단.

→ 한 InvoiceNo에 여러 상품이 있으면 각 상품에 대해 중복으로 카운트된다.

즉, 내가 구하는 건 취소된 거래 수가 아니라 취소된 상품 수이다.

따라서 거래 수를 카운트하려면 1이 아니라 InvoiceNo가 되어야 하고, distinct로 중복을 제외해야 한다.

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
select * FROM `white-might-456101-t9.modulabs_project.user_data`;
```

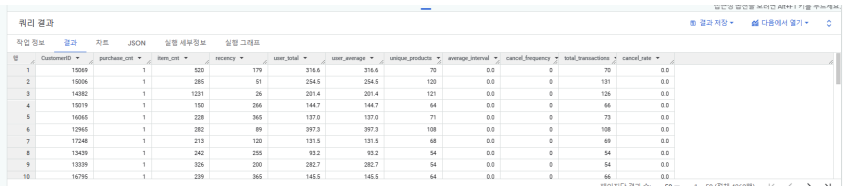

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval	cancel_frequency	total_transactions	cancel_rate
1	15069	1	520	179	316.6	316.6	70	0.0	0	70	0.0
2	15006	1	285	51	254.5	254.5	120	0.0	0	131	0.0
3	14382	1	1231	26	201.4	201.4	121	0.0	0	126	0.0
4	15019	1	150	366	144.7	144.7	64	0.0	0	66	0.0
5	16065	1	228	365	137.0	137.0	71	0.0	0	73	0.0
6	12965	1	282	89	397.3	397.3	108	0.0	0	108	0.0
7	17248	1	213	120	131.5	131.5	68	0.0	0	69	0.0
8	13439	1	242	255	93.2	93.2	54	0.0	0	54	0.0
9	13339	1	326	200	282.7	282.7	54	0.0	0	54	0.0
10	16795	1	239	365	145.5	145.5	64	0.0	0	66	0.0

회고

Keep :

1. 중간에 잘못된 부분을 인지하고, 정확한 문제 원인 파악 후 해결하려고 한 점.
2. 데이터와 테이블을 모두 삭제하고 새로 생성한 점에서 시간 지체가 있었지만 끝까지 포기하지 않은 점.
3. 다시 푸는 과정에서 RFM 개념과 코드를 더 꼼꼼하게 이해할 수 있었던 점.

Problem :

1. UnitPrice가 0이 아닌 데이터로 테이블 생성해야 하는데 0인 데이터로 잘못 넣어서 반이상을 다시 해야했음.
2. 문법적인 개념 학습이 더 필요하고, RFM을 처음 알게 된 개념이라서 이해하고 푸는데 시간이 걸렸다.

Try :

1. 이해가 안 가는 개념은 질문을 통해 해결하고, 정답 코드와 비교하며 코드 리뷰해야겠다.
2. Syntax error부분을 다시 정리해야겠다.
3. 너무 큰 실수는 하지 않도록 해야겠다.